

Zadání projektu z předmětu IPP 2018/2019

Zbyněk Křivka

E-mail: krivka@fit.vutbr.cz

1 Základní charakteristika projektu

Navrhněte, implementujte, dokumentujte a testujte sadu skriptů pro interpretaci nestrukturovaného imperativního jazyka IPPcode19. K implementaci vytvořte odpovídající stručnou programovou dokumentaci. Projekt se skládá ze dvou úloh a je individuální.

První úloha se skládá ze skriptu `parse.php` v jazyce PHP 7.3 (viz sekce 3). Druhá úloha se skládá ze skriptu `interpret.py` v jazyce Python 3.6 (viz sekce 4), testovacího skriptu `test.php` v jazyce PHP 7.3 (viz sekce 5) a dokumentace těchto skriptů (viz sekce 2.1).

2 Požadavky a organizační informace

Kromě implementace skriptů a vytvoření dokumentace je třeba dodržet také řadu následujících formálních požadavků. Pokud některý nebude dodržen, může být projekt hodnocen nula body!

Termíny:

Připomínky¹ k zadání projektu do 11. února 2019;

Fixace zadání projektu od 12. února 2019;

Odevzdání první úlohy ve středu **13. března** 2019 do 23:59:59;

Odevzdání druhé úlohy v neděli **11. dubna** 2019 do 23:59:59.

Dodatečné informace a konzultace k projektu z IPP:

- *Wiki* předmětu IPP v IS FIT včetně Často kladených otázek (*FAQ*)
- *Fórum* předmětu IPP pro ak. rok 2018/2019, témata IPP: **Projekt.***
- U cvičících: Dominika Regéciová (iregeciova@fit.vutbr.cz), Martin Tomko (itomko@fit.vutbr.cz), Radim Krčmář (ikrcmar@fit.vutbr.cz), Jakub Martiško (imartisko@fit.vutbr.cz)
- Zbyněk Křivka (garant projektu): dle konzultačních slotů (viz webová stránka) nebo po dohodě e-mailem (uvádějte předmět začínající "IPP: "), viz <http://www.fit.vutbr.cz/~krivka>
- Dušan Kolář (garant předmětu; jen v závažných případech): po dohodě e-mailem (uvádějte předmět začínající "IPP: "), viz <http://www.fit.vutbr.cz/~kolar>

¹Zadání je zcela nové, takže naleznete-li v zadání nějakou chybu či nejasnost, dejte mi prosím vědět na *Fóru* předmětu nebo emailem na krivka@fit.vutbr.cz. Validní připomínky a upozornění na chyby budou oceněny i bonusovými body.

Pokud máte jakékoliv dotazy, problémy, či nejasnosti ohledně tohoto projektu, tak po přečtení *FAQ* a *Fóra* předmětu (využívejte i možnosti hledání na *Fóru*), neváhejte napsat na *Fórum* (u obecného problému, jenž se potenciálně týká i Vašich kolegů) či kontaktovat cvičícího, garanta projektu (v případě individuálního problému), nebo nouzově garanta předmětu, kdy do předmětu vždy uveďte na začátek řetězec "IPP:". Na problémy zjištěné v řádu hodin až jednotek dní před termínem odevzdání některé části projektu nebude brán zřetel. Začněte proto projekt řešit s dostatečným předstihem.

Forma a způsob odevzdání: Každá úloha se odevzdává individuálně prostřednictvím IS FIT v předmětu IPP (odevzdání emailem není možné nebo je bodově postihováno) a odevzdáním stvrzujete výhradní autorství skriptů i dokumentace.

Do termínu „Projekt - 1. úloha v PHP 7.3“ odevzdáte archiv pro první úlohu v jazyce PHP 7.3 (skript `parse.php`; včetně dokumentace tohoto skriptu). Po termínu odevzdání 1. úlohy bude otevřen termín „Projekt - 2. úloha v Pythonu 3.6 a testovací skript v PHP 7.3“ pro odevzdání archivu pro druhou úlohu (skripty `interpret.py` a `test.php`; včetně dokumentace pro obsažené skripty). Součástí archivu první úlohy mohou být i nedokončené skripty a dokumentace odevzdávané k hodnocení až v druhé úloze a naopak v archivu druhé úlohy se smí vyskytovat skript z první úlohy a adresář s vašimi testy. Pro hodnocení skriptu `test.php` není třeba odevzdávat 1. úlohu. V případě odevzdání již plně funkčního skriptu `test.php` v rámci archivu 1. úlohy lze získat 1 bonusový bod.

Každá úloha bude odevzdána ve zvláštním archivu, kde budou soubory k dané úloze zkomprimovány programem ZIP, TAR+GZIP či TAR+BZIP do jediného archivu pojmenovaného `xlogin99.zip`, `xlogin99.tgz`, nebo `xlogin99.tbz`, kde `xlogin99` je Váš login. Velikost každého archivu bude omezena informačním systémem (pravděpodobně na 1 MB). Archiv nesmí obsahovat speciální či binární spustitelné soubory. Názvy všech souborů mohou obsahovat pouze písmena anglické abecedy, číslice, tečku, pomlčku a podtržítka. **Skripty budou umístěny v kořenovém adresáři odevzdaného archivu.** Po rozbalení archivu na serveru Merlin bude možné skript(y) spustit. Archiv smí obsahovat v rozumné míře pomocné adresáře (typicky pro vaše vlastní testy, vaše knihovny a pomocné skripty nebo povolené knihovny, které nejsou nainstalovány na serveru Merlin).

Hodnocení:

Výše základního bodového hodnocení projektu v předmětu IPP je **maximálně 20 bodů**. Navíc lze získat maximálně 5 bonusových bodů za kvalitní a podařené řešení některého z rozšíření nebo kvalitativně nadprůměrnou účast na *Fóru* projektu apod.

Hodnocení jednotlivých skriptů: `parse.php` až 6 bodů; `interpret.py` až 8 bodů; `test.php` až 3 body. Tj. v součtu až **17 bodů**. Dokumentace bude dohromady hodnocena až **3 body** (až 1 bod za popis skriptu `parse.php` a až 2 body za popis skriptů `interpret.py` a `test.php`), avšak maximálně 30 % ze sumy hodnocení skriptů dané úlohy (tedy v případě neodevzdání žádného funkčního skriptu v dané úloze bude samotná dokumentace hodnocena 0 body). Body za každou úlohu včetně její dokumentace se pro vložení do IS FIT zaokrouhlují na desetinu bodu.

Skripty budou spouštěny na serveru Merlin příkazem: `interpret skript parametry`, kde `interpret` bude `php7.3` nebo `python3.6`, `skript` a `parametry` závisí na dané úloze a skriptu. Hodnocení většiny funkčnosti bude zajišťovat automatizovaný nástroj. Kvalitu dokumentace, komentářů a strukturu zdrojového kódu budou hodnotit cvičící.

Podmínky pro opakující studenty ohledně případného uznání hodnocení loňského projektu najdete v *FAQ* na *Wiki* předmětu.

Registrovaná rozšíření: V případě implementace některých registrovaných rozšíření za bonusové body bude odevzdaný archiv obsahovat soubor `rozsireni`, ve kterém uvedete na každém řádku identifikátor jednoho implementovaného rozšíření² (řádky jsou ukončeny znakem LF, tj. znak s dekadickou ASCII hodnotou 10). V průběhu řešení mohou být zaregistrována nová rozšíření úlohy za bonusové body (viz *Fórum* předmětu IPP). Nejpozději do termínu pokusného odevzdání dané úlohy můžete cvičícímu přes *Fórum* zasílat návrhy na nová netriviální rozšíření, která byste chtěli navíc implementovat. Cvičící rozhodne o přijetí/nepřijetí rozšíření a hodnocení rozšíření dle jeho náročnosti včetně přiřazení unikátního identifikátoru. Implementovaná rozšíření neidentifikovaná v souboru `rozsireni` nebudou hodnocena.

Pokusné odevzdání: Pro zvýšení motivace studentů pro včasné vypracování úloh nabízíme koncept nepovinného pokusného odevzdání. Výměnou za pokusné odevzdání do uvedeného termínu (cca týden před finálním termínem) dostanete zpětnou vazbu v podobě zařazení do některého z pěti rozmezí hodnocení (0–10 %, 11–30 %, 31–50 %, 51–80 %, 81–100 %). Bude-li Vaše pokusné odevzdání v prvním rozmezí hodnocení, máte možnost osobně konzultovat důvod, pokud jej neodhalíte sami. U ostatních rozmezí nebudou detailnější informace poskytovány.

Pokusné odevzdání bude relativně rychle vyhodnoceno automatickými testy a studentům zaslána orientační informace o správnosti pokusně odevzdané úlohy z hlediska části automatických testů (tj. nebude se jednat o finální hodnocení; proto nebudou sdělovány ani body či přesnější procentuální hodnocení). Využití pokusného termínu není povinné, ale jeho nevyužití může být negativně vzato v úvahu v případě reklamace hodnocení projektu.

Formální požadavky na pokusné odevzdání jsou totožné s požadavky na finální termín a odevzdání se bude provádět do speciálních termínů „Projekt - Pokusné odevzdání 1. úlohy“ do **6. března 2019** a „Projekt - Pokusné odevzdání 2. úlohy“ do **3. dubna 2019**. Není nutné zahrnout dokumentaci, která spolu s rozšířeními pokusně vyhodnocena nebude. U skriptu `test.php` bude pokusné hodnocení omezeno jen na velmi základní automatizovatelné testy (bez manuální kontroly skutečného obsahu).

2.1 Dokumentace

Implementační dokumentace (dále jen dokumentace) musí být stručným a uceleným průvodcem **Vašeho způsobu řešení** skriptů 1. i 2. úlohy. Bude vytvořena ve formátu **PDF** nebo **Markdown** (viz [4]). Jakékoliv jiné formáty dokumentace než PDF či Markdown³ (přípona `md`) budou ignorovány, což povede ke ztrátě bodů za dokumentaci. Dokumentaci je možné psát buď česky⁴ (s diakritikou, formálně čistě), nebo anglicky (formálně čistě).

Dokumentace bude popisovat celkovou filozofii návrhu, způsob a Váš specifický postup řešení (např. řešení sporných případů nedostatečně upřesněných zadáním, konkrétní řešení rozšíření, případné využití návrhových vzorů, implementované/nedokončené vlastnosti). Dokumentace může být doplněna např. o UML diagram tříd, navržený konečný automat, pravidla Vámi vytvořené gramatiky nebo popis jiných formalismů a algoritmů. Nicméně **nesmí obsahovat ani částečnou kopii zadání**.

Rozsah textu dokumentace pro každý skript bude přibližně 1 normostrana. Vysázená dokumentace 1. úlohy popisující skript `parse.php` by neměla přesáhnout 1 stranu A4 a u 2. úlohy (popisující skripty `interpret.py` a `test.php`) pak 2 strany A4. Doporučení pro sazbu: 10-bodové písmo Times New Roman pro text a Courier pro identifikátory a skutečně krátké úryvky zajímavého kódu;

²Identifikátory rozšíření jsou uvedeny u konkrétního rozšíření tučně.

³Bude-li přítomna dokumentace v Markdown i PDF, tak bude hodnocena verze v PDF, kde je jistější sazba.

⁴Možnost použít slovenštinu je upřesněna v *FAQ* na *Wiki* předmětu.

nevkládejte žádnou zvláštní úvodní stranu, obsah ani závěr. V rozumné míře je vhodné používat nadpisy první a druhé úrovně (12-bodové a 11-bodové písmo Times New Roman) pro vytvoření logické struktury dokumentace.

Nadpis a hlavička dokumentace⁵ bude na prvních třech řádcích obsahovat:

Implementační dokumentace k %cislo%. úloze do IPP 2018/2019

Jméno a příjmení: %name_surname%

Login: %xlogin99%

kde %name_surname% je Vaše jméno a příjmení, %xlogin99% Váš login a %cislo% je číslo dokumentované úlohy.

Dokumentace bude v kořenovém adresáři odevzdaného archívu a pojmenována `readme1.pdf` nebo `readme1.md` pro první úlohu a `readme2.pdf` nebo `readme2.md` pro druhou úlohu.

V rámci dokumentace bude hodnoceno i komentování zdrojového kódu (minimálně každá funkce a modul (třída) by měly mít svůj komentář o jejich účelu a parametrech; u složitějších funkcí okomentujte i omezení na vstupy či výstupy).

2.2 Programová část

Zadání projektu vyžaduje implementaci tří skriptů⁶, které mají parametry příkazové řádky a je definováno, jakým způsobem manipulují se vstupy a výstupy. Skript (vyjma `test.php`) nesmí spouštět žádné další procesy či příkazy operačního systému. Veškerá chybová hlášení, varování a ladicí výpisy směřujte pouze na standardní chybový výstup, jinak pravděpodobně nedodržíte zadání kvůli modifikaci definovaných výstupů (ať již do externích souborů nebo do standardního výstupu). Jestliže proběhne činnost skriptu bez chyb, vrací se návratová hodnota 0 (nula). Jestliže došlo k nějaké chybě, vrací se chybová návratová hodnota větší jak nula. Chyby mají závazné chybové návratové hodnoty:

- 10 - chybějící parametr skriptu (je-li třeba) nebo použití zakázané kombinace parametrů;
- 11 - chyba při otevírání vstupních souborů (např. neexistence, nedostatečné oprávnění).
- 12 - chyba při otevření výstupních souborů pro zápis (např. nedostatečné oprávnění).
- 20 – 69 - návratové kódy chyb specifických pro jednotlivé skripty;
- 99 - interní chyba (neovlivněná vstupními soubory či parametry příkazové řádky; např. chyba alokace paměti).

Pokud zadání nestanoví níže jinak, tak veškeré vstupy a výstupy jsou v kódování UTF-8. Pro účely projektu z IPP musí být na serveru Merlin ponecháno implicitní nastavení `locale`⁷, tj. `LC_ALL=cs_CZ.UTF-8`.

Jména hlavních skriptů jsou dána zadáním. Pomocné skripty nebo knihovny budou mít příponu dle zvyklostí v daném programovacím jazyce (`.php` pro PHP 7 a `.py` pro Python 3). Vyhodnocení skriptů bude prováděno na serveru Merlin s aktuálními verzemi interpretů (dne 1. 2. 2019 bylo na tomto serveru nainstalováno `php7.3`⁸ verze 7.3.1 a `python3.6`⁹ verze 3.6.8).

⁵Anglické znění nadpisu a hlavičky dokumentace najdete v *FAQ* na *Wiki* předmětu.

⁶Tyto skripty jsou aplikace příkazové řádky neboli konzolové aplikace.

⁷Správné nastavení prostředí je nezbytné, aby bylo možné používat a správně zpracovávat parametry příkazové řádky v UTF-8. Pro správnou funkčnost je třeba mít na UTF-8 nastaveno i kódování znakové sady konzole (např. u programu PuTTY v kategorii *Window.Translation* nastavíte *Remote character set* na UTF-8). Pro změnu ovlivňující aktuální sezení lze využít unixový příkaz `export LC_ALL=cs_CZ.UTF-8`.

⁸Upozornění: Na serveru Merlin je třeba dodržet testování příkazem `php7.3`, protože pouhým `php` se spouští verze, která nemá přístup k souborovému systému!

⁹Upozornění: Na serveru Merlin je třeba dodržet testování příkazem `python3.6`, protože pouhým `python` se spouští stará nekompatibilní verze! Python 3.x není zpětně kompatibilní s verzí 2.x!

K řešení lze využít standardně předinstalované knihovny obou jazykových prostředí na serveru **Merlin**. V případě využití jiné knihovny kromě knihovny podporující načítání/ukládání formátu XML, zpracování parametrů příkazové řádky a zpracování regulárních výrazů je třeba konzultovat s garantem projektu (především z důvodu, aby se řešení projektu použitím vhodné knihovny nestalo zcela triviálním). Seznam povolených a zakázaných knihoven bude udržován aktuální na *Wiki* předmětu. Ve skriptech v jazyce PHP jsou některé funkce z bezpečnostních důvodů zakázány (např. `header`, `mail`, `popen`, `curl_exec`, `socket_*`; úplný seznam je u povolených/zakázaných knihoven na *Wiki*).

Každý skript bude pracovat s jedním společným parametrem:

- `--help` vypíše na standardní výstup nápovědu skriptu (nenačítá žádný vstup), kterou lze převzít ze zadání (lze odstranit diakritiku, případně přeložit do angličtiny dle zvoleného jazyka dokumentace). Tento parametr nelze kombinovat s žádným dalším parametrem, jinak skript ukončete s chybou 10.

Kombinovatelné parametry skriptů jsou odděleny alespoň jedním bílým znakem a mohou být uváděny v libovolném pořadí, pokud nebude řečeno jinak. U skriptů je možné implementovat i vaše vlastní nekolizní parametry (doporučujeme konzultaci na *Fóru* nebo u cvičícího).

Není-li řečeno jinak, tak dle konvencí unixových systémů lze uvažovat zástupné zkrácené (s jednou pomlčkou) i dlouhé parametry (se dvěma pomlčkami), které lze se zachováním sémantiky zaměňovat (tzv. alias parametry), ale testovány budou vždy dlouhé verze.

Je-li součástí parametru i soubor (např. `--source=file` nebo `--source="file"`), tak tento soubor může být zadán relativní cestou¹⁰ nebo absolutní cestou; výskyt znaku uvozovek a rovnítko ve *file* neuvažujte.

3 Analyzátor kódu v IPPcode19 (parse.php)

Skript typu filtr (`parse.php` v jazyce PHP 7.3) načte ze standardního vstupu zdrojový kód v IPPcode19 (viz sekce 6), zkontroluje lexikální a syntaktickou správnost kódu a vypíše na standardní výstup XML reprezentaci programu dle specifikace v sekci 3.1.

Tento skript bude pracovat s těmito parametry:

- `--help` viz společný parametr všech skriptů v sekci 2.2

Chybové návratové kódy specifické pro analyzátor:

- 21 - chybná nebo chybějící hlavička ve zdrojovém kódu zapsaném v IPPcode19.
- 22 - neznámý nebo chybný operační kód ve zdrojovém kódu zapsaném v IPPcode19.
- 23 - jiná lexikální nebo syntaktická chyba zdrojového kódu zapsaného v IPPcode19.

3.1 Popis výstupního XML formátu

Za povinnou XML hlavičkou¹¹ následuje kořenový element `program` (s povinným textovým atributem `language` s hodnotou IPPcode19), který obsahuje pro instrukce elementy `instruction`. Každý element `instruction` obsahuje povinný atribut `order` s pořadím instrukce (počítáno od 1) a povinný

¹⁰Relativní cesta nebude obsahovat zástupný symbol `~` (vlnka).

¹¹Tradiční XML hlavička včetně verze a kódování je `<?xml version="1.0" encoding="UTF-8"?>`

atribut `opcode` (hodnota operačního kódu je ve výstupním XML vždy velkými písmeny) a elementy pro odpovídající počet operandů/argumentů: `arg1` pro případný první argument instrukce, `arg2` pro případný druhý argument a `arg3` pro případný třetí argument instrukce. Element pro argument má povinný atribut `type` s možnými hodnotami `int`, `bool`, `string`, `nil`, `label`, `type`, `var` podle toho, zda se jedná o literál, návěští, typ nebo proměnnou, a obsahuje textový element.

Tento textový element potom nese buď hodnotu literálu (již bez určení typu a bez znaku `@`), nebo jméno návěští, nebo typ, nebo identifikátor proměnné (včetně určení rámce a `@`). U proměnných ponechávejte označení rámce vždy velkými písmeny (samotné jméno proměnné ponechejte beze změny). V případě číselných literálů je zápis ponechán ve formátu ze zdrojového kódu (např. `zůstana` kladná znaménka čísel nebo počáteční přebytkové nuly) a není třeba kontrolovat jejich lexikální správnost (na rozdíl od řetězových literálů). U literálů typu `string` při zápisu do XML nepřevádějte původní escape sekvence, ale pouze pro problematické znaky v XML (např. `<`, `>`, `&`) využijte odpovídající XML entity (např. `<`, `>`, `&`). Podobně převádějte problematické znaky vyskytující se v identifikátorech proměnných. Literály typu `bool` vždy zapisujte malými písmeny jako `false` nebo `true`.

Doporučení: Všimněte si, že analýza IPPcode19 je tzv. kontextově závislá (viz přednášky), kdy například můžete mít klíčové slovo použito jako návěští a z kontextu je třeba rozpoznat, zda jde o návěští nebo ne. Při tvorbě analyzátoru doporučujeme kombinovat konečně-stavové řízení a regulární výrazy a pro generování výstupního XML využít vhodnou knihovnu.

Výstupní XML bude porovnáváno s referenčními výsledky pomocí nástroje A7Soft JExamXML¹², viz [2].

3.2 Bonusová rozšíření

STATP Sbírá statistiky zpracovaného zdrojového kódu v IPPcode19. Skript bude podporovat parametr `--stats=file` pro zadání souboru *file*, kam se agregované statistiky budou vypisovat (po řádcích dle pořadí v dalších parametrech; na každý řádek nevypisujte nic kromě požadovaného číselného výstupu). Parametr `--loc` vypíše do statistik počet řádků s instrukcemi (nepočítají se prázdné řádky, ani řádky obsahující pouze komentář, ani úvodní řádek). Parametr `--comments` vypíše do statistik počet řádků, na kterých se vyskytoval komentář. Parametr `--labels` vypíše do statistik počet definovaných návěští (tj. unikátních možných cílů skoku). Parametr `--jumps` vypíše do statistik počet instrukcí pro podmíněné a nepodmíněné skoky dohromady. Chybí-li při zadání `--loc`, `--comments`, `--labels` nebo `--jumps`, parametr `--stats`, jedná se o chybu 10 [1 b].

4 Interpret XML reprezentace kódu (`interpret.py`)

Program načte XML reprezentaci programu ze zadaného souboru a tento program s využitím standardního vstupu a výstupu interpretuje. Vstupní XML reprezentace je např. generována skriptem `parse.php` (ale ne nutně) ze zdrojového kódu v IPPcode19. Interpret navíc oproti sekci 3.1 podporuje existenci volitelných dokumentačních textových atributů `name` a `description` v kořenovém elementu `program`. Sémantika jednotlivých instrukcí IPPcode19 je popsána v sekci 6.

Tento skript bude pracovat s těmito parametry:

¹²Nastavení A7Soft JExamXML pro porovnávání XML (soubor `options`) je v *Souborech* k projektu v IS FIT.

- `--help` viz společný parametr všech skriptů v sekci 2.2
- `--source=file` vstupní soubor s XML reprezentací zdrojového kódu dle definice ze sekce 3.1
- `--input=file` soubor se vstupy pro samotnou interpretaci zadaného zdrojového kódu

Alespoň jeden z parametrů (`--source` nebo `--input`) musí být vždy zadán. Pokud jeden z nich chybí, tak jsou odpovídající data načítána ze standardního vstupu.

Chybové návratové kódy specifické pro interpret:

- 31 - chybný XML formát ve vstupním souboru (soubor není tzv. dobře formátovaný, angl. *well-formed* (viz [1])).
- 32 - neočekávaná struktura XML či lexikální nebo syntaktická chyba textových elementů a atributů ve vstupním XML souboru (např. chybný lexém pro řetězcový literál, neznámý operační kód apod.).

Chybové návratové kódy interpretu v případě chyby během interpretace jsou uvedeny v popisu jazyka IPPcode19 (viz sekce 6.1).

Doporučení: Doporučujeme použít knihovnu pro načítání XML. V případě nekompletní implementace se zaměřte na funkčnost globálního rámce, práce s proměnnými typu `int`, instrukce `WRITE` a instrukce pro řízení toku programu.

4.1 Bonusová rozšíření

FLOAT Podpora typu `float` v IPPcode19 (**hexadecimální zápis** v analyzátoru i v interpretu včetně načítání ze standardního vstupu; např. `float@0x1.2000000000000p+0` reprezentuje 1,125; viz funkce `float.fromhex()` a `float.hex()` v Python 3). Podporujte instrukce pro práci s tímto typem: `INT2FLOAT`, `FLOAT2INT`, aritmetické instrukce (včetně `DIV`), atd. (viz [3]). Podpora v `parse.php` je možná, ale nebude testována. [1 b]

STACK Podpora zásobníkových variant instrukcí (přípona `S`; viz [3]): `CLEARs`, `ADDs/SUBs`, `MULs/IDIVs`, `LTS/GTS/EQS`, `ANDs/ORS/NOTs`, `INT2CHARs`, `STR2INTs` a `JUMPIFEQS/JUMPIFNEQS`. Zásobníkové verze instrukcí z datového zásobníku vybírají operandy se vstupními hodnotami dle popisu tříadresné instrukce od konce (tj. typicky nejprve $\langle symb_2 \rangle$ a poté $\langle symb_1 \rangle$). Podpora v `parse.php` je možná, ale nebude testována. [1 b]

STATI Sbírání statistik interpretace kódu. Skript bude podporovat parametr `--stats=file` pro zadání souboru *file*, kam se agregované statistiky budou vypisovat (po řádcích dle pořadí v dalších parametrech; na každý řádek nevypisujte nic kromě požadovaného číselného výstupu). Podpora parametru `--insts` pro výpis počtu vykonaných instrukcí během interpretace do statistik. Podpora parametru `--vars` pro výpis maximálního počtu inicializovaných proměnných přítomných ve všech platných rámcích během interpretace zadaného programu do statistik. Chybí-li při zadání `--insts` či `--vars` parametr `--stats`, jedná se o chybu 10. [1 b]

5 Testovací rámec (`test.php`)

Skript (`test.php` v jazyce PHP 7.3) bude sloužit pro automatické testování postupné aplikace `parse.php` a `interpret.py`¹³. Skript projde zadaný adresář s testy a využije je pro automatické otestování správné funkčnosti obou předchozích programů včetně vygenerování přehledného souhrnu v HTML 5 do standardního výstupu. Testovací skript nemusí u předchozích dvou skriptů testovat jejich dodatečnou funkčnost aktivovanou parametry příkazové řádky (s výjimkou potřeby parametru `--source`).

Tento skript bude pracovat s těmito parametry:

- `--help` viz společný parametr všech skriptů v sekci 2.2
- `--directory=`*path* testy bude hledat v zadaném adresáři (chybí-li tento parametr, tak skript prochází aktuální adresář)
- `--recursive` testy bude hledat nejen v zadaném adresáři, ale i rekurzivně ve všech jeho podadresářích
- `--parse-script=`*file* soubor se skriptem v PHP 7.3 pro analýzu zdrojového kódu v IPPcode19 (chybí-li tento parametr, tak implicitní hodnotou je `parse.php` uložený v aktuálním adresáři)
- `--int-script=`*file* soubor se skriptem v Python 3.6 pro interpret XML reprezentace kódu v IPPcode19 (chybí-li tento parametr, tak implicitní hodnotou je `interpret.py` uložený v aktuálním adresáři)
- `--parse-only` bude testován pouze skript pro analýzu zdrojového kódu v IPPcode19 (tento parametr se nesmí kombinovat s parametrem `--int-script`)
- `--int-only` bude testován pouze skript pro interpret XML reprezentace kódu v IPPcode19 (tento parametr se nesmí kombinovat s parametrem `--parse-script`)

Každý test je tvořen až 4 soubory stejného jména s příponami `src`, `in`, `out` a `rc` (ve stejném adresáři). Soubor s příponou `src` obsahuje zdrojový kód v jazyce IPPcode19. Soubory s příponami `in`, `out` a `rc` obsahují vstup a očekávaný/referenční výstup interpretace a očekávaný první chybový návratový kód analýzy a interpretace nebo bezchybový návratový kód 0. Pokud soubor s příponou `in` nebo `out` chybí, tak se automaticky dogeneruje prázdný soubor. V případě chybějícího souboru s příponou `rc` se vygeneruje soubor obsahující návratovou hodnotu 0.

Testy budou umístěny v adresáři včetně případných podadresářů pro lepší kategorizaci testů. Adresářová struktura může mít libovolné zanoření. Není třeba uvažovat symbolické odkazy apod.

Požadavky na výstupní HTML verze 5: Přehledová stránka o úspěšnosti/neúspěšnosti jednotlivých testů a celých adresářů bude přehlednuta ručně opravujícím, takže bude hodnocena její přehlednost a intuitivnost. Mělo by být na první pohled zřejmé, které testy uspěly a které nikoli a zda případně uspěly všechny testy (případně i po jednotlivých adresářích). Výsledná stránka nesmí načítat externí zdroje¹⁴ a musí být možné ji zobrazit v běžném prohlížeči.

¹³Za tímto účelem lze vytvářet dočasné soubory, které však nesmí přepsat žádný jiný existující soubor a potom musí být uklizeny.

¹⁴Přímo do generované HTML stránky je možné vložit vlastní JavaScript nebo CSS kód.

Doporučení: Pro porovnávání mezi skutečným výstupem a referenčním výstupem v souboru s příponou `out` použijte unixový nástroj příkazové řádky `diff`.

5.1 Bonusová rozšíření

FILES Podporujte parametr `--testlist=file` slouží pro explicitní zadání seznamu adresářů (zadaných relativními či absolutními cestami) a případně i souborů s testy (zadáva se soubor s příponou `.src`) formou externího souboru `file` místo načtení testů z aktuálního adresáře (nelze kombinovat s parametrem `--directory`). Dále podporujte parametr `--match=regex` pro výběr testů, jejichž jméno bez přípony (ne cesta) odpovídá zadanému regulárnímu výrazu `regex` dle PCRE syntaxe. [1 b]

V případě odevzdání již plně funkčního skriptu `test.php` v rámci archívu 1. úlohy lze získat 1 bonusový bod.

6 Popis jazyka IPPcode19

Nestrukturovaný imperativní jazyk IPPcode19 vznikl úpravou jazyka IFJcode18 (jazyk pro mezikód překladače jazyka IFJ18, viz [3]), který zahrnuje instrukce tříadresné (typicky se třemi argumenty) a případně zásobníkové (typicky méně parametrů a pracující s hodnotami na datovém zásobníku). Každá instrukce se skládá z operačního kódu (klíčové slovo s názvem instrukce), u kterého nezáleží na velikosti písmen (tj. case insensitive). Zbytek instrukcí tvoří operandy, u kterých na velikosti písmen záleží (tzv. case sensitive). Operandy oddělujeme libovolným nenulovým počtem mezer či tabulátorů. Také před operačním kódem a za posledním operandem se může vyskytnout libovolný počet mezer či tabulátorů. Odřádkování slouží pro oddělení jednotlivých instrukcí, takže na každém řádku je maximálně jedna instrukce a není povoleno jednu instrukci zapisovat na více řádků. Každý operand je tvořen proměnnou, konstantou, typem nebo návěští. V IPPcode19 jsou podporovány jednořádkové komentáře začínající mřížkou (`#`). Kód v jazyce IPPcode19 začíná úvodním řádkem s tečkou následovanou jménem jazyka (nezáleží na velikosti písmen):

.IPPcode19

6.1 Návrátové hodnoty interpretu

Proběhne-li interpretace bez chyb, vrací se návratová hodnota 0 (nula). Chybovým případům odpovídají následující návratové hodnoty:

- 52 - chyba při sémantických kontrolách vstupního kódu v IPPcode19 (např. použití nedefinovaného návěští).
- 53 - běhová chyba interpretace – špatné typy operandů.
- 54 - běhová chyba interpretace – přístup k neexistující proměnné (rámec existuje).
- 55 - běhová chyba interpretace – rámec neexistuje (např. čtení z prázdného zásobníku rámců).
- 56 - běhová chyba interpretace – chybějící hodnota (v proměnné, na datovém zásobníku, nebo v zásobníku volání).
- 57 - běhová chyba interpretace – špatná hodnota operandu (např. dělení nulou, špatná návratová hodnota instrukce EXIT).
- 58 - běhová chyba interpretace – chybná práce s řetězcem.

6.2 Paměťový model

Hodnoty během interpretace nejčastěji ukládáme do pojmenovaných proměnných, které jsou sdružovány do tzv. rámců, což jsou v podstatě slovníky proměnných s jejich hodnotami. IPPcode19 nabízí tři druhy rámců:

- globální, značíme GF (Global Frame), který je na začátku interpretace automaticky inicializován jako prázdný; slouží pro ukládání globálních proměnných;
- lokální, značíme LF (Local Frame), který je na začátku nedefinován a odkazuje na vrcholový/aktuální rámec na zásobníku rámců; slouží pro ukládání lokálních proměnných funkcí (Zásobník rámců lze s výhodou využít při zanořeném či rekurzivním volání funkcí.);
- dočasný, značíme TF (Temporary Frame), který slouží pro chystání nového nebo úklid starého rámce (např. při volání nebo dokončování funkce), jenž může být přesunut na zásobník rámců a stát se aktuálním lokálním rámcem. Na začátku interpretace je dočasný rámec nedefinovaný.

K překrytým (dříve vloženým) lokálním rámcům v zásobníku rámců nelze přistoupit dříve, než vyjmeme později přidané rámce.

Další možností pro ukládání nepojmenovaných hodnot je datový zásobník využívaný zásobníkovými instrukcemi.

6.3 Datové typy

IPPcode19 pracuje s typy operandů dynamicky, takže je typ proměnné (resp. paměťového místa) dán obsaženou hodnotou. Není-li řečeno jinak, jsou implicitní konverze zakázány. Interpret podporuje speciální hodnotu/typ `nil` a tři základní datové typy (`int`, `bool` a `string`), jejichž rozsahy i přesnosti jsou kompatibilní s jazykem Python 3.

Zápis každé konstanty v IPPcode19 se skládá ze dvou částí oddělených zavináčem (znak `@`; bez bílých znaků), označení typu konstanty (`int`, `bool`, `string`) a samotné konstanty (číslo, literál). Např. `bool@true`, `nil@nil` nebo `int@-5`.

Typ `int` reprezentuje celé číslo (přetečení/podtečení neřešte). Typ `bool` reprezentuje pravdivostní hodnotu (`false` nebo `true`). Literál pro typ `string` je v případě konstanty zapsán jako sekvence tisknutelných znaků v kódování UTF-8 (vyjma bílých znaků, mřížky (`#`) a zpětného lomítka (`\`)) a escape sekvencí, takže není ohraničen uvozovkami. Escape sekvence, která je nezbytná pro znaky s dekadickým kódem 000-032, 035 a 092, je tvaru `\xyz`, kde `xyz` je dekadické číslo v rozmezí 000-999 složené právě ze tří číslic¹⁵; např. konstanta

```
string@řetězec\032s\032lomítkem\032\092\032a\010novým\035řádkem
```

reprezentuje řetězec

```
řetězec s lomítkem \ a  
novým#řádkem
```

Pokus o práci s neexistující proměnnou (čtení nebo zápis) vede na chybu 54. Pokus o čtení hodnoty neinicializované proměnné vede na chybu 56. Pokus o interpretaci instrukce s operandy nevhodných typů dle popisu dané instrukce vede na chybu 53.

¹⁵Zápis znaků s kódem Unicode větším jak 127 pomocí těchto escape sekvencí nebudeme testovat.

6.4 Instrukční sada

U popisu instrukcí sázíme operační kód tučně a operandy zapisujeme pomocí neterminálních symbolů (případně číslovaných) v úhlových závorkách. Neterminál $\langle var \rangle$ značí proměnnou, $\langle symb \rangle$ konstantu nebo proměnnou, $\langle label \rangle$ značí návěští. Identifikátor proměnné se skládá ze dvou částí oddělených zavináčem (znak @; bez bílých znaků), označení rámce LF, TF nebo GF a samotného jména proměnné (sekvence libovolných alfanumerických a speciálních znaků bez bílých znaků začínající písmenem nebo speciálním znakem, kde speciální znaky jsou: $_$, $-$, $\$$, $\&$, $\%$, $*$, $!$, $?$). Např. GF@_x značí proměnnou _x uloženou v globálním rámci.

Na zápis návěští se vztahují stejná pravidla jako na jméno proměnné (tj. část identifikátoru za zavináčem).

Příklad jednoduchého programu v IPPcode19:

```
. IPPcode19
DEFVAR GF@counter
MOVE GF@counter string@ #Inicializace proměnné na prázdný řetězec
#Jednoduchá iterace, dokud nebude splněna zadaná podmínka
LABEL while
JUMPIFEQ end GF@counter string@aaa
WRITE string@counter\032obsahuje\032
WRITE GF@counter
WRITE string@\010
CONCAT GF@counter GF@counter string@a
JUMP while
LABEL end
```

Instrukční sada nabízí instrukce pro práci s proměnnými v rámcích, různé skoky, operace s datovým zásobníkem, aritmetické, logické a relační operace, dále také konverzní, vstupní/výstupní a ladicí instrukce.

6.4.1 Práce s rámcí, volání funkcí

MOVE $\langle var \rangle$ $\langle symb \rangle$

Přiřazení hodnoty do proměnné

Zkopíruje hodnotu $\langle symb \rangle$ do $\langle var \rangle$. Např. MOVE LF@par GF@var provede zkopírování hodnoty proměnné var v globálním rámci do proměnné par v lokálním rámci.

CREATEFRAME

Vytvoř nový dočasný rámec

Vytvoří nový dočasný rámec a zahodí případný obsah původního dočasného rámce.

PUSHFRAME

Přesun dočasného rámce na zásobník rámců

Přesuň TF na zásobník rámců. Rámec bude k dispozici přes LF a překryje původní rámec na zásobníku rámců. TF bude po provedení instrukce nedefinován a je třeba jej před dalším použitím vytvořit pomocí CREATEFRAME. Pokus o přístup k nedefinovanému rámci vede na chybu 55.

POPFRAME

Přesun aktuálního rámce do dočasného

Přesuň vrcholový rámec LF ze zásobníku rámců do TF. Pokud žádný rámec v LF není k dispozici, dojde k chybě 55.

DEFVAR $\langle var \rangle$

Definuj novou proměnnou v rámci

Definuje proměnnou v určeném rámci dle $\langle var \rangle$. Tato proměnná je zatím neinicializovaná a bez určení typu, který bude určen až přiřazením nějaké hodnoty.

CALL $\langle label \rangle$ Skok na návěští s podporou návratu
 Uloží inkrementovanou aktuální pozici z interního čítače instrukcí do zásobníku volání a provede skok na zadané návěští (případnou přípravu rámce musí zajistit jiné instrukce).

RETURN Návrat na pozici uloženou instrukcí CALL
 Vyjme pozici ze zásobníku volání a skočí na tuto pozici nastavením interního čítače instrukcí (úklid lokálních rámců musí zajistit jiné instrukce).

6.4.2 Práce s datovým zásobníkem

Operační kód zásobníkových instrukcí je zakončen písmenem „S“. Zásobníkové instrukce případně načítají chybějící operandy z datového zásobníku a výslednou hodnotu operace případně ukládají zpět na datový zásobník.

PUSHS $\langle symb \rangle$ Vlož hodnotu na vrchol datového zásobníku
 Uloží hodnotu $\langle symb \rangle$ na datový zásobník.

POPS $\langle var \rangle$ Vyjmi hodnotu z vrcholu datového zásobníku
 Není-li zásobník prázdný, vyjme z něj hodnotu a uloží ji do proměnné $\langle var \rangle$, jinak dojde k chybě 56.

6.4.3 Aritmetické, relační, booleovské a konverzní instrukce

V této sekci jsou popsány tříadresné instrukce pro klasické operace pro výpočet výrazu. Přetečení nebo podtečení číselného výsledku neřešte.

ADD $\langle var \rangle \langle symb_1 \rangle \langle symb_2 \rangle$ Součet dvou číselných hodnot
 Sečte $\langle symb_1 \rangle$ a $\langle symb_2 \rangle$ (musí být typu int) a výslednou hodnotu téhož typu uloží do proměnné $\langle var \rangle$.

SUB $\langle var \rangle \langle symb_1 \rangle \langle symb_2 \rangle$ Odečítání dvou číselných hodnot
 Odečte $\langle symb_2 \rangle$ od $\langle symb_1 \rangle$ (musí být typu int) a výslednou hodnotu téhož typu uloží do proměnné $\langle var \rangle$.

MUL $\langle var \rangle \langle symb_1 \rangle \langle symb_2 \rangle$ Násobení dvou číselných hodnot
 Vynásobí $\langle symb_1 \rangle$ a $\langle symb_2 \rangle$ (musí být typu int) a výslednou hodnotu téhož typu uloží do proměnné $\langle var \rangle$.

IDIV $\langle var \rangle \langle symb_1 \rangle \langle symb_2 \rangle$ Dělení dvou celočíselných hodnot
 Celočíselně podělí celočíselnou hodnotu ze $\langle symb_1 \rangle$ druhou celočíselnou hodnotou ze $\langle symb_2 \rangle$ (musí být oba typu int) a výsledek typu int přiřadí do proměnné $\langle var \rangle$. Dělení nulou způsobí chybu 57.

LT/GT/EQ $\langle var \rangle \langle symb_1 \rangle \langle symb_2 \rangle$ Relační operátory menší, větší, rovno
 Instrukce vyhodnotí relační operátor mezi $\langle symb_1 \rangle$ a $\langle symb_2 \rangle$ (stejného typu; int, bool nebo string) a do booleovské proměnné $\langle var \rangle$ zapíše **false** při neplatnosti nebo **true** v případě platnosti odpovídající relace. Řetězce jsou porovnávány lexikograficky a **false** je menší než **true**. Pro výpočet neostrých nerovností lze použít AND/OR/NOT. S operandem typu nil lze porovnávat pouze instrukcí EQ, jinak chyba 53.

AND/OR/NOT $\langle var \rangle \langle symb_1 \rangle \langle symb_2 \rangle$ Základní booleovské operátory
 Aplikuje konjunkci (logické A)/disjunkci (logické NEBO) na $\langle symb_1 \rangle$ a $\langle symb_2 \rangle$ nebo negaci na $\langle symb_1 \rangle$ (NOT má pouze 2 operandy) a výsledek zapíše do $\langle var \rangle$ (všechny operandy jsou typu bool).

INT2CHAR $\langle var \rangle \langle symb \rangle$ Převod celého čísla na znak
 Číselná hodnota $\langle symb \rangle$ je dle Unicode převedena na znak, který tvoří jednoznakový řetězec přiřazený do $\langle var \rangle$. Není-li $\langle symb \rangle$ validní ordinální hodnota znaku v Unicode (viz funkce **chr** v Python 3), dojde k chybě 58.

STR2INT $\langle var \rangle$ $\langle symb_1 \rangle$ $\langle symb_2 \rangle$	Ordinální hodnota znaku
Do $\langle var \rangle$ uloží ordinální hodnotu znaku (dle Unicode) v řetězci $\langle symb_1 \rangle$ na pozici $\langle symb_2 \rangle$ (indexováno od nuly). Indexace mimo daný řetězec vede na chybu 58. Viz funkce <code>ord</code> v Python 3.	

6.4.4 Vstupně-výstupní instrukce

READ $\langle var \rangle$ $\langle type \rangle$	Načtení hodnoty ze standardního vstupu
Načte jednu hodnotu dle zadaného typu $\langle type \rangle \in \{\text{int}, \text{string}, \text{bool}\}$ a uloží tuto hodnotu do proměnné $\langle var \rangle$. Načtení proveďte vestavěnou funkcí <code>input()</code> jazyka Python 3, pak proveďte konverzi na specifikovaný typ $\langle type \rangle$. Při převodu vstupu na typ <code>bool</code> nezáleží na velikosti písmen a řetězec „true“ se převádí na <code>bool@true</code> , vše ostatní na <code>bool@false</code> . V případě chybného vstupu bude do proměnné $\langle var \rangle$ uložena implicitní hodnota (dle typu 0, prázdný řetězec nebo <code>false</code>).	

WRITE $\langle symb \rangle$	Výpis hodnoty na standardní výstup
Vypíše hodnotu $\langle symb \rangle$ na standardní výstup. Až na typ <code>bool</code> je formát výpisu kompatibilní s příkazem <code>print</code> jazyka Python 3.	

6.4.5 Práce s řetězci

CONCAT $\langle var \rangle$ $\langle symb_1 \rangle$ $\langle symb_2 \rangle$	Konkatenace dvou řetězců
Do proměnné $\langle var \rangle$ uloží řetězec vzniklý konkatenací dvou řetězcových operandů $\langle symb_1 \rangle$ a $\langle symb_2 \rangle$ (jiné typy nejsou povoleny).	

STRLEN $\langle var \rangle$ $\langle symb \rangle$	Zjistí délku řetězce
Zjistí počet znaků (délku) řetězce v $\langle symb \rangle$ a tato délka je uložena jako celé číslo do $\langle var \rangle$.	

GETCHAR $\langle var \rangle$ $\langle symb_1 \rangle$ $\langle symb_2 \rangle$	Vrať znak řetězce
Do $\langle var \rangle$ uloží řetězec z jednoho znaku v řetězci $\langle symb_1 \rangle$ na pozici $\langle symb_2 \rangle$ (indexováno celým číslem od nuly). Indexace mimo daný řetězec vede na chybu 58.	

SETCHAR $\langle var \rangle$ $\langle symb_1 \rangle$ $\langle symb_2 \rangle$	Změň znak řetězce
Zmodifikuje znak řetězce uloženého v proměnné $\langle var \rangle$ na pozici $\langle symb_1 \rangle$ (indexováno celočíselně od nuly) na znak v řetězci $\langle symb_2 \rangle$ (první znak, pokud obsahuje $\langle symb_2 \rangle$ více znaků). Výsledný řetězec je opět uložen do $\langle var \rangle$. Při indexaci mimo řetězec $\langle var \rangle$ nebo v případě prázdného řetězce v $\langle symb_2 \rangle$ dojde k chybě 58.	

6.4.6 Práce s typy

TYPE $\langle var \rangle$ $\langle symb \rangle$	Zjistí typ daného symbolu
Dynamicky zjistí typ symbolu $\langle symb \rangle$ a do $\langle var \rangle$ zapíše řetězec značící tento typ (<code>int</code> , <code>bool</code> , <code>string</code> nebo <code>nil</code>). Je-li $\langle symb \rangle$ neinicializovaná proměnná, označí její typ prázdným řetězcem.	

6.4.7 Instrukce pro řízení toku programu

Neterminál $\langle label \rangle$ označuje návěští, které slouží pro označení pozice v kódu IPPcode19. V případě skoku na neexistující návěští dojde k chybě 52.

LABEL $\langle label \rangle$	Definice návěští
Speciální instrukce označující pomocí návěští $\langle label \rangle$ důležitou pozici v kódu jako potenciální cíl libovolné skokové instrukce. Pokus o redefinici existujícího návěští je chybou 52.	

JUMP $\langle label \rangle$	Nepodmíněný skok na návěští
Provede nepodmíněný skok na zadané návěští $\langle label \rangle$.	

JUMPIFEQ $\langle label \rangle$ $\langle symb_1 \rangle$ $\langle symb_2 \rangle$ Podmíněný skok na návěští při rovnosti
Pokud jsou $\langle symb_1 \rangle$ a $\langle symb_2 \rangle$ stejného typu (jinak chyba 53) a zároveň se jejich hodnoty rovnají, tak provede skok na návěští $\langle label \rangle$.

JUMPIFNEQ $\langle label \rangle$ $\langle symb_1 \rangle$ $\langle symb_2 \rangle$ Podmíněný skok na návěští při nerovnosti
Jsou-li $\langle symb_1 \rangle$ a $\langle symb_2 \rangle$ stejného typu (jinak chyba 53), ale různé hodnoty, tak provede skok na návěští $\langle label \rangle$.

EXIT $\langle symb \rangle$ Ukončení interpretace s návratovým kódem
Ukončí vykonávání programu a ukončí interpret s návratovou chybou $\langle symb \rangle$, kde $\langle symb \rangle$ je celé číslo v intervalu 0 až 49 (včetně). Nevalidní celočíselná hodnota $\langle symb \rangle$ vede na chybu 57.

6.4.8 Ladící instrukce

Následující ladící instrukce (DPRINT a BREAK) nesmí ovlivňovat standardní výstup. Jejich skutečnou funkcionalitu nebudeme testovat, ale mohou se v testech objevit.

DPRINT $\langle symb \rangle$ Výpis hodnoty na `stderr`
Předpokládá se, že vypíše zadanou hodnotu $\langle symb \rangle$ na standardní chybový výstup (`stderr`).

BREAK Výpis stavu interpretu na `stderr`
Předpokládá se, že na standardní chybový výstup (`stderr`) vypíše stav interpretu (např. pozice v kódu, obsah rámců, počet vykonaných instrukcí) v danou chvíli (tj. během vykonávání této instrukce).

Reference

- [1] Extensible Markup Language (XML) 1.0. W3C. World Wide Web Consortium [online]. 5. vydání. 26. 11. 2008 [cit. 2018-02-05]. Dostupné z: <https://www.w3.org/TR/xml/>
- [2] A7Soft JExamXML is a java based command line XML diff tool for comparing and merging XML documents. c2017 [cit. 2018-02-05]. Dostupné z: <http://www.a7soft.com/jexamxml.html>
- [3] Křivka, Z., a kol.: Zadání projektu z předmětu IFJ a IAL. c2018 [cit. 2019-01-30]. Dostupné z: <https://www.fit.vutbr.cz/study/courses/IFJ/private/projekt/ifj2018.pdf>
- [4] The text/markdown Media Type. Internet Engineering Task Force (IETF). 2016 [cit. 2019-02-06]. Dostupné z: <https://tools.ietf.org/html/rfc7763>